位點與表達性負責人
作業流程 SOP

長江杯 2026 全球 AI 蛋白質設計大賽 ／ 賽制對標 Anthropic × Adaptyv Protein Design Competition
版本 v1.0 • 2026 年 10 月 29 日 • 適用於 10 人隊伍中負責 表位選擇（epitope selection）、熱點定義（hotspot definition）、表達（expression）與表達性（expressibility）的成員

> **在開始前必須知道的兩件事。**
>
> 一、**長江杯的官方競賽規程不在公開網路上。**靶點、每隊提交上限、長度與格式限制、「統一標準化篩選」的指標、獎金分配方式全部未公開。本 SOP 的所有數值約束來自 Adaptyv 公開的四屆賽事資料與平台文件，是**代理假設**，拿到規程後必須逐條覆核。
>
> 二、本文件中標示為〔**未驗證**〕的內容請勿當作既成事實使用，附錄 C 集中列出。

0 • 角色定義與交付物

這個角色不是「幫生物組看看結構」。在一個計算指標排不出親和力的競賽裡，這條線是**全隊唯一有可靠量化依據的環節**——胺基酸組成預測表達的判別力勝過所有結構置信度分數。你的工作同時決定了計算組跑什麼（上游）與送出什麼（下游）。

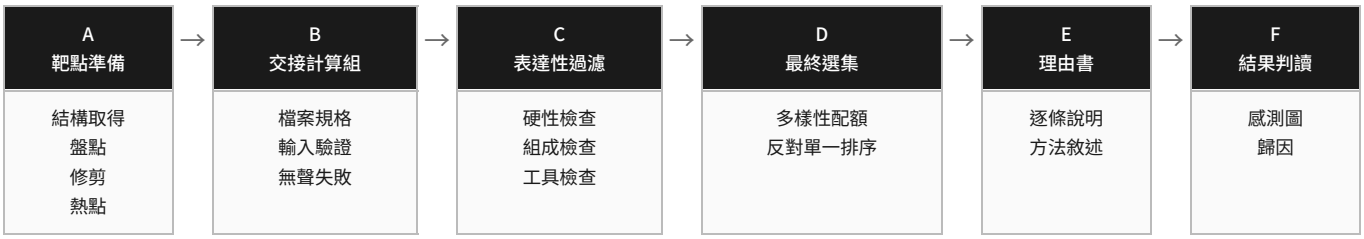
交付物	內容	交給誰	什麼時候
靶點檔案 target dossier	修剪後的 PDB 檔（含 SHA-256 雜湊）× 3–4 個版本、每版一組熱點字串、表位選擇的書面理由、禁區標記	計算組（RFdiffusion / BindCraft 的直接輸入）	專案第 1 週結束前，之後凍結
表達性過濾器 expressibility filter	硬性格式檢查 + 組成檢查 + 溶解度工具檢查的腳本與判定規則；對每條候選序列給出通過／退回／條件通過	最終選集流程（你有否決權）	第 2 週建好，之後每批設計都跑
設計理由書 design rationale	表位選擇依據、方法敘述、每條送出序列的個別說明	主辦方（隨提交）	提交前 3 天完稿

> **為什麼理由書是你的工作，而且不是行政文件。**Adaptyv Round 2 的 400 個濕實驗測試名額中，只有 100 個按計算分數取；**另外 300 個按設計者對自身設計流程描述的品質與新穎性分配**，並保證每位有寫描述的參賽者至少獲得 1 個名額。Round 1 的 726 份投稿裡，**398 份因描述缺失或不清而被排除在分析之外**。寫作在這個賽制裡是直接換取實驗名額的。

與其他角色的邊界

- **你負責**：靶點結構的選擇與修剪、表位與熱點、所有與表達／溶解度相關的過濾、最終選集的多樣性配額、理由書、結果回來後的感測圖判讀。
- **你不負責**：跑 RFdiffusion／BindCraft 的環境與批次、模型版本管理、重新評分（re-scoring）的實作。
- **你有否決權而非建議權的地方**：任何一條沒通過表達性過濾的序列不得送出；反向摺疊（inverse folding）最後一步必須是 SolubleMPNN。理由見 §4.4。

1 • 流程總覽



A 與 B 是一次性的（但 A 要同時產出多個版本）；C 與 D 每批設計重複；E 在提交前；F 在資料回來後，產出下一輪的輸入。

2 · 階段 A：靶點準備

這是整條管線中**單一變異性最大**的輸入。同一個靶點的不同修剪版本，計算成功率差異顯著；而靶點本身的選擇對結果的支配力大於工具選擇——BindCraft 對 PD-L1 的計算成功率 66%，對多數靶點不到 10%；同一個 Adaptyv 平台上的實測命中率從 2.5%（EGFR Round 1）到 37%（TREM2 2026）。

A-1 · 取得結構

1. 優先取**實驗結構（experimental structure）**。若有複合物結構更好——它直接告訴你天然配體佔的是哪個面（例：EGF–EGFR 複合物 PDB `1IVO`；2026 ICLR/GEM 賽的 RBX-1/ROC1 為 UniProt `P62877`，108 殘基）。
2. 缺環（missing loops）可用實驗結構當模板重新預測來補。
3. 同時下載 AlphaFold 資料庫的預測版本，留作第三個候選版本。
4. **確認構築體邊界。**主辦方拿去做實驗的那段序列，不一定等於你手上 PDB 的那段。這個落差會讓你設計的表面在試管裡根本不存在。規程沒公開前，這一條是待確認項。

A-2 · 盤點（在修剪之前）

用 ChimeraX 或 PyMOL 開啟，逐項記錄：

☐ 結構域（domain）邊界在哪、各域的殘基範圍

☐ 柔性區：高 B-factor 區段（實驗結構）或低 pLDDT 區段（預測結構）

☐ 功能面：天然配體／已知抗體結合的位置

☐ 醣基化位點（glycosylation sites）——無細胞系統不做醣基化，若靶點是醣蛋白，設計用的結構與試管裡的分子存在系統性落差

☐ 非目標鏈與不需要的 loop

☐ 疏水性表面斑塊的位置與大小

> **表位的兩個選擇標準，順序不可顛倒。**
>
> **一、功能相關性。**Adaptyv Round 2 把**中和（neutralisation）**當成與結合分開的指標測量（0–100% 阻斷天然配體）。一個只優化解離常數（KD）的設計可以在親和力上贏、在功能上完全無用。選一個與配體結合位重疊的表位，能讓兩個指標同向。
>
> **二、可設計性。**主辦方的回顧明確指出：**高度可及、疏水、柔性較低**的表面成功率較高。

A-3 · 修剪規程（trimming protocol）

修剪有兩個同時成立的動機。生物動機：讓管線把注意力放在你要的面上。計算動機：顯存（GPU memory）是硬約束——32 GB 顯卡約可容納 550 殘基（靶點 + 結合物），80 GB 約 950 殘基；而一個 900 殘基的軌跡在 H100 上要 2–3 小時，250 殘基只要約 5 分鐘。**修剪幅度直接決定全隊跑得起多少設計。**

步驟

1. 移除非目標鏈。
2. 移除柔性末端（flexible termini）與不需要的 loop。
3. 在**結構域邊界或鉸鏈殘基（hinge residues，典型為 Gly、Pro）**處切；用高 B-factor／低 pLDDT 定位這些位置。
4. **刪除整個殘基，不要留下半截原子。**殘留的部分殘基會讓 BindCraft 噴 `Mismatched atoms` 錯誤。
5. 檢查切完之後有沒有把疏水核心暴露出來。不真實的修剪是可以接受的——**只要局部結構保留且核心疏水殘基沒被翻到表面。**
6. 重複產出 **3–4 個不同的修剪版本**（例如：只留目標結構域／留目標結構域加鄰接域／預測結構版本／保守修剪版本）。
7. 對每個版本計算 SHA-256 雜湊並記錄。

> **為什麼雜湊值不是形式主義。**修剪版本的差異會顯著改變成功率，而它是整條管線裡**最容易被無痕修改**的輸入——有人在本地「順手清理」一下 PDB，跑出來的結果就不可歸因了。設計登錄表裡每一條設計都必須帶著它所用靶點檔案的雜湊值。

A-4 · 熱點選擇規程（hotspot selection）

規則	具體做法
熱點是一塊斑塊，不是一個殘基	BindCraft 作者指示定義**數個構成一個斑塊的表面殘基**。RFdiffusion 的 README 建議 3–6 個熱點殘基。對定義極清楚的位點，單一殘基也可行。
偏好二級結構	選落在 α 螺旋或 β 折疊上的殘基，避開 loop。Round 1 的 BindCraft 冠軍打的就是 EGFR 的 β 折疊界面。
偏好大疏水與芳香族殘基	F、Y、W、I、L、M
留空也是一個選項	熱點設為 `null` 時由 AlphaFold2 自行挑位點。可以當作對照組跑一批，看模型自己偏好哪裡——這本身是情報。
格式必須對上	BindCraft： `A23,A27-50,B45` （數字 + 鏈 ID，可用範圍）。RFdiffusion： `ppi.hotspot_res=[A30,A33,A34]` 。**PDB 裡的鏈標籤必須與你寫的完全一致**，不一致會無聲失敗。

負向設計：把管線趕離你不要的位點

三種做法，可疊加：

1. 把該位點的殘基突變成**離胺酸（lysine）**——帶電、親水，模型會避開。
2. 把該區段整段切掉。
3. 先放一個已知結合物把那個面擋住。

另有 `_hardtarget` 設定可用於困難靶點。

> **「熱點被忽略」是設計行為，不是 bug。**當 BindCraft 跑出來的設計不打你指定的位點，這代表那個位點不好——模型找到了一個分數更高的面。此時不要去調參數硬壓，先回頭檢查表位選擇是否合理；若該位點是功能必需，就用上面的負向設計把替代位點封掉。另外注意：即使做了負向設計，管線仍可能偏好別處。

A-5 • 靶點檔案規格

交給計算組的是一個資料夾，內含：

項目	規格
修剪後 PDB × 3–4	檔名含版本標識；每個檔案附 SHA-256
熱點字串表	每個 PDB 版本對應一組或多組熱點字串，兩種格式都寫（BindCraft 用與 RFdiffusion 用）
禁區標記	哪些面不要、用什麼方式封（突變成 K／切除／擋住）
表位理由	200–400 字：為什麼這個面、功能相關性為何、可及性與柔性的依據
長度建議	結合物長度範圍（見 §4.1）
格式決定	奈米抗體（VHH）／微型結合蛋白（minibinder）／scFv，見 §4.1

3 · 階段 B：交接給計算組

這個介面的設計原則是：**不要把計算組的人訓練成生物學家，也不要自己去學跑管線**。你提供數值範圍與約束，他們的程式負責在超出範圍時報錯。

B-1 · 輸入驗證器（input validator）

要求計算組在每次跑批前執行一個驗證腳本，斷言以下五件事。這些錯誤的共同特徵是**會產出看起來正常的結果**，不會報錯。

斷言	為什麼
結合物是第一條鏈	`dl_binder_design` 要求結合物為第一條鏈
殘基索引跨鏈唯一	`predict.py` 要求結合物與靶點的殘基索引不得重複
熱點字串裡的每個鏈 ID 都存在於該 PDB	鏈標籤不符會導致熱點被靜默忽略
PDB 中沒有部分殘基	修剪殘留會造成 `Mismatched atoms`
靶點檔案雜湊值與登錄表記載一致	防止無痕修改

B-2 · 設計登錄表（design registry）

每一條設計都要有一列紀錄。**在產生時寫入，不要事後補**。你需要的欄位（與你的職責相關的部分）：

- 設計 ID（穩定、唯一）
- 生成器名稱 + 固定的 commit／檢查點檔名、隨機種子（seed）
- **所用靶點檔案的雜湊值**、contig／長度規格、熱點字串
- 反向摺疊模型名稱與溫度（必須記錄是否為 SolubleMPNN）
- 每一項過濾值 + 當時生效的閾值集版本
- 若被拒，是哪一道過濾拒的
- 你的表達性檢查結果（通過／退回／條件通過）
- 是否送出

4 · 階段 C：表達性過濾

這道關卡的成本效益是整個專案裡最高的。表達失敗在 2026 年已不是主要瓶頸（Round 1 損失 27%，Round 2 僅約 5%，TREM2 賽約 11%），但它**便宜到沒有理由損失任何一條設計**。

C-1 · 硬性格式檢查（不通過即退回，無例外）

項目	限制	備註
長度	≤ 250 殘基〔依 2026 GEM 賽規〕；付費服務為 8–700 殘基	更小更好：較小的設計與較高表達相關；超過 50 kDa 成功率下降
鏈數	單鏈	scFv 要含自己的連接子（linker）；Fab 需配對鏈且另計費
胺基酸	僅 20 種標準胺基酸	無非天然胺基酸
標籤與訊號肽	提交序列不得含標籤（tag）或訊號肽（signal peptide）	Adaptyv 會自行接上一個標準標籤；**標籤的身分與端點未公開〔未驗證〕**
VHH 格式	必須提交完整結構域	不能只交 CDR；平台不把設計接進固定骨架
IgG	不支援	Fc 區在無細胞系統表達不佳；改送 scFv 或 Fab
新穎性	2026：與 UniRef50 的編輯距離 ≥ 25%／序列同一性 ≤ 75%（頁面兩種說法）。EGFR 賽為與已知結合物相差 > 10 個胺基酸	**Round 1 有兩個數十 nM 的結合物因此被取消資格**。接近邊界時取較嚴格的解讀

C-2 · 組成檢查

這是本 SOP 裡判別力最強的一組數字。在 Round 2 的 378 條實測資料上，單一殘基組成對「高表達」的判別力勝過所有結構置信度分數：

特徵	ROC AUC	方向
麩胺酸（glutamate, E）比例	**0.77**	高者佳
離胺酸（lysine, K）比例	**0.73**	高者佳
Rosetta 溶劑化能（solvation energy）／殘基	0.68	—
長程主鏈氫鍵能（H-bond energy）／殘基	0.68	—
α 螺旋比例	0.67	高者佳
ipTM	0.58	幾乎無用
pLDDT	0.55	幾乎無用
ESM 偽對數似然（pseudo-log-likelihood）	**0.44**	**比隨機猜還差**

> **這組數字的機制解讀。**E 與 K 都是帶電殘基，高 E／高 K 本質上是一條**表面電荷（surface charge）規則**的偽裝：帶電、親水的表面在擁擠的無細胞混合液裡不容易聚集。這也解釋了為什麼它比結構置信度分數有用——置信度分數回答「這個形狀合不合理」，表達問的是「它在這管液體裡會不會黏成一團」。
>
> 同一份資料裡另有一個反向例子：TREM2 賽中 AI 代理設計的序列**丙胺酸（alanine）佔比異常高**、多樣性低，其表達失敗率 19%，人類隊伍 7%。無人監督的生成管線會漂進人類加一道溶解度過濾就會否決的組成區間。

你要寫的檢查腳本（約 20 行）

輸入序列，輸出：

- E 比例、K 比例、E+K 比例、淨電荷（net charge）
- **半胱胺酸（cysteine）奇偶性**——見下方說明
- 最長連續疏水片段長度、疏水殘基總比例
- 最長同聚物串（homopolymer run）、重複片段偵測
- 序列長度、估算分子量

本批次的 E／K 比例應與 Round 2 公開資料集中高表達組的分布對照，而非用一個絕對閾值。公開資料沒有給疏水斑塊大小、表面電荷或淨電荷的數值門檻，規則只到定性層次（「平衡」「長斑塊」）。〔見附錄 C〕

> **關於雙硫鍵的更正：比一般 de novo 設計的民間規矩寬鬆。**Adaptyv 的無細胞系統**明確為含雙硫鍵的蛋白優化過**——含 DsbC 雙硫鍵異構酶（disulfide bond isomerase）加上氧化型與還原型穀胱甘肽（glutathione）構成的氧化還原緩衝。所以**設計雙硫鍵是可行的**。真正的規則是**半胱胺酸奇偶性**：不要有落單（未配對）的 Cys，因為它會形成非預期的雙硫鍵。檢查配對狀態，不要一律禁用 Cys。

C-3 ・ 工具檢查

工具	用途	判讀
NetSolP	序列層級的快速溶解度分流	usability 較高者表達較好
SoluProt	大腸桿菌可溶表達預測	與 NetSolP 搭配使用，兩者皆為平台推薦
Aggrescan3D	聚集傾向（aggregation propensity）	分數較低者表達較好

平台另提到基於暴露度的疏水性度量（如 pSAE）可用來排序聚集風險，但各工具實作不一。

C-4 ・ 強制要求：反向摺疊的最後一步必須是 SolubleMPNN

這是本 SOP 中**單位努力回報最高的一條**。Goverde 等人在同一個重新設計的蛋白上只替換反向摺疊模型：

模型	表達成功率	樣本
標準 ProteinMPNN	**0%**	0 / 12
親水性偏置版本	75%	6 / 8
SolubleMPNN	**93.1%**	27 / 29

整個競賽 Round 1 → Round 2 的表達率從 73% 升到 95%，主因就是參賽者開始為溶解度共同優化——Round 1 時幾乎沒人管表達，絕大多數人只盯 iPAE。主辦方在 Round 1 回顧中的建議是：**提交前跑一次 SolubleMPNN 作為最終檢查**。

C-5 • 判定規則

判定	條件	處置
退回	任一項 C-1 硬性格式檢查不過	不得送出，無例外
退回	半胱胺酸數目為奇數且無法解釋	要求用 SolubleMPNN 重做該位置
條件通過	組成落在低表達分布區，但設計在其他維度有獨特價值（例：唯一打到某個表位的設計）	可送，但必須在登錄表標記，且計入 §5 的風險配額
通過	格式合規、Cys 偶數、組成落在高表達分布、三項工具無紅旗	進入最終選集池

5 · 階段 D：最終選集

本階段的核心反模式：按單一分數由高到低取前 N 名。這在公開資料裡是一種有紀錄的輸法。

- Round 1 的第二名（KD 4.77 μM）在主辦方的 iPAE 排名裡是**第 54 名**；第三名（KD 22.9 μM）是**第 89 名**。
- Round 2 的總冠軍 Cradle，其參賽序列在計算排名中位於**第 322–623 名**，是靠人工挑選與每位參賽者的保底名額才進到測試。
- 反過來，把單一分數推到榜首的隊伍在濕實驗裡全部落空。

原因在於：結構置信度分數衡量**幾何可信度**，而結合由模型從未被訓練過的能量學決定。這些分數是有效的**負向過濾器（negative filter）**——用來砍掉底部；它們不是排序器。

D-1 · 選集方法

1. **先累積足量。**BindCraft 作者的建議是先收集 **≥ 100 條通過預設過濾、且界面多樣**的設計，再從中篩選；目標為奈米莫耳級（nanomolar）結合物約需實測 10 條，皮莫耳級（picomolar）需 50–100 條。
2. **用過濾器砍底部，不要用它排頂部。**
3. **按多樣性配額取樣**，而非按分數排序（見下表）。
4. **保留少數未通過過濾的設計。**Round 3 的 de novo 冠軍（10 條中 9 條結合）其設計**沒有一條通過 BindCraft 的預設過濾**。保留是理性的對沖，不是草率。
5. **逐條目視檢查。**在 ChimeraX／PyMOL 裡看界面：是不是同一個面的近複本、界面有沒有壓在柔性區、有沒有把疏水核心翻出來、結合界面是否緊貼 N／C 端（因為 Adaptyv 會在端點接標籤，而生物層干涉術（BLI）是把結合物固定、抗原流過，端點附近的界面可能被固定化本身擋住）。

D-2 · 多樣性配額（範本，依名額總數縮放）

分類	配額	理由
主表位 × 高表達組成	~40%	基本盤
主表位 × 不同骨架拓樸／長度	~20%	同一個面也要換形狀去試
次表位	~20%	每靶點的可預測性差異極大，不要把名額押在一個面上
非 α 螺旋為主的設計	~10%	生成模型偏好全螺旋；這是對模型偏差的對沖
風險配額（過濾失敗但目視良好）	~10%	見上方 Round 3 冠軍案例

一份橫跨 15 個靶點、3,766 條設計的統合分析指出，各項指標的平均精確度（average precision）在不同靶點間從 0.1 到 1.0 都有——**你無法事先知道你的過濾器在你的靶點上有沒有用**。該分析給出的名額受限策略是：先以結合物 RMSD < 3.73、形狀互補性（shape complementarity）> 0.62 預過濾，再按 AF3 ipSAE_min 取前 K 名，此法在全部 15 個靶點上都以約 10 條候選找回至少一個結合物。

6 · 階段 E：設計理由書

見 §0 的名額分配機制。建議結構：

段落	內容
1. 靶點與表位	選了哪個面、功能相關性（是否與配體結合位重疊）、可及性與柔性的結構依據、引用的 PDB 條目
2. 靶點準備	修剪策略與切點依據、產出了幾個版本、各版本的結果差異
3. 熱點定義	熱點字串與選擇理由；若做了負向設計，說明封了哪個面、怎麼封
4. 生成方法	工具、版本字串、檢查點、軌跡數、並行軌道的設計
5. 過濾與選集	**明確說明為什麼沒有按單一分數排序**，以及多樣性配額的構成——這一段是與多數投稿的區別點
6. 表達性共同優化	SolubleMPNN、組成檢查、溶解度工具；引用組成訊號強於置信度分數的依據
7. 逐條說明	每條送出的設計：打哪個表位、屬於哪個配額、為什麼留它
8. 新穎性聲明	與已知結合物的距離、所用的比對方法與資料庫

7 · 階段 F：結果判讀

F-1 • 回來的是什麼

項目	規格
表達量	四級分類（高／中／低／無）；**低於 0.02 μg/mL 排除於結合分析之外**。小型 de novo 蛋白典型產量 50–600 μg/mL，scFv 50–300 μg/mL
結合	二元判定
親和力	以 1:1 模型擬合的 kon、koff、KD；訊號太弱或動力學太快時改用平衡分析（equilibrium analysis）
條件	抗原 1000 → 10 nM 滴定、雙重複、HBS-T + 0.5% BSA、25 °C
時程	提交至資料釋出約 2–3 週；表達 QC 約在第 8–9 天

F-2 • 感測圖（sensorgram）判讀清單

☐ 結合相與解離相是真實訊號，還是漂移（drift）、體相位移（bulk shift）或非特異性結合

☐ 平坦或方波狀的軌跡是假影，不是結果

☐ 1:1 擬合的殘差（residuals）是否良好——殘差差則該 KD 無效

☐ koff 極快時被迫改用平衡分析，弱端的 KD 只是估計值

☐ 滴定窗口 10–1000 nM 意味著**弱於約 μM 的設計無法可靠表徵**（Round 1 第三名的 22.9 μM 就在可測量性邊緣）

☐ 雙重複之間是否一致

F-3 • 失敗歸因

觀察	可能歸因	下一輪動作
表達「無」	聚集、mRNA 二級結構、高疏水性、重複序列、異常組成	回 §4.2 檢查該條的組成；檢討過濾器為何放行
表達良好、完全不結合	Baker 實驗室框架的 Type 2：摺疊正確但不結合。或表位不可及、靶點構象不符、構築體不符	換表位，不是換工具
整批都不結合	表位選擇錯誤，或設計用結構與試管裡的分子不符	回階段 A；檢查醣基化與構築體邊界
結合但不中和	打到了功能無關的面	回階段 A-2 的功能相關性標準

附錄 A ・ 數字速查

A.1 ・ 歷屆基礎比率

賽事	命中率	表達率	最佳 KD 與方法
EGFR Round 1（2024）	2.5%（5/201）	73%	491 nM，BindCraft 預設設定
EGFR Round 2（2024–25）	13.2%（~53/378）	95%	1.21 nM，Cradle（抗體框架工程，非 de novo）。最佳 de novo：RFdiffusion 51.6 nM、BindCraft 82 nM
Nipah（2025–26）	9.6%	—	de novo 冠軍 10 條中 9 條結合
CD45（BindCraft）	25%	—	—
TREM2（2026）	37%	89%	人類最佳 1.11 nM；AI 代理最佳 3.64 nM

命中率的跨度主要是**靶點效應**，不是方法世代效應。Round 1 與 Round 2 的 KD 分布以克-瓦檢定（Kruskal-Wallis）比較無顯著差異（**p = 0.374**）——兩年的工具進步讓命中率提高約 5 倍，但 de novo 的親和力天花板沒有實質移動。對照組西妥昔單抗（cetuximab）為 9.94 nM，Round 2 的 400 條中只有 2 條追平或超越它。

A.2 ・ BindCraft 預設過濾閾值

這是本領域唯一完整公開的閾值集（`default_filters.json`）。作者建議**不要動預設值**。

指標	閾值	方向
pLDDT	0.8	高於
i_pTM	0.5	高於
i_pAE	0.35	**低於**
ShapeComplementarity 形狀互補性	0.6 / 0.55	高於
dSASA	1	高於
n_InterfaceResidues 界面殘基數	7	高於
n_InterfaceHbonds 界面氫鍵數	3	高於
UnsatHbonds 未飽和氫鍵	4	低於
Surface_Hydrophobicity 表面疏水性	0.35	低於
Binder_RMSD	3.5	低於
Average_Hotspot_RMSD	6	低於
InterfaceAAs K / M	3	低於
MPNN_score、MPNN_seq_recovery	**預設停用（null）**——作者刻意為之	

> **兩個已知衝突。**（一）BindCraft 論文寫未飽和氫鍵 < 3，但隨程式發布的 JSON 用 4 ——**以 JSON 為準**。（二）i_pAE 的 0.35 是正規化尺度，PXDesign 把同一道過濾重述為 ipAE < 10.85，**兩個數字是同一件事的兩種刻度**，這是隊內混淆的必然來源，請在登錄表裡註明用的是哪種刻度。

A.3 ・ 算力換算（供你評估修剪幅度用）

項目	數值
250 殘基軌跡（H100）	約 5 分鐘
900 殘基軌跡（H100）	約 2–3 小時
H100 相對 A100	約快 4 倍
Google Colab 相對本地	約慢 10 倍
顯存對應規模	16 GB ≈ 250 殘基；32 GB ≈ 550；80 GB ≈ 950
所需軌跡數	容易靶點約 100；困難靶點 1,000–10,000
肽（peptide）結合物	計算成功率預期**低 5–10 倍**

把 900 殘基修剪到 250 殘基，單條軌跡成本差約 30 倍。**這是支持積極修剪的最強論據，而修剪是你的工作。**

附錄 B ・ 五天上手計劃

日	主題	時數	內容與理由
D1	置信度指標在算什麼，以及不算什麼	3–4 h	EMBL-EBI AlphaFold 課程的 confidence scores 模組與 AF3 quality assessment 模組（約 2 h）；讀 Adaptyv 社群論文的結論與圖（1.5 h）。 **理由**：你之後會頻繁需要對計算組說「這條 ipTM 0.9 的我不要，那條 0.6 的我要」。講不清 pLDDT／pTM／ipTM／預測對齊誤差（PAE）各自在算什麼，這個對話你吵不贏——而資料站在你這邊。
D2	熱點與修剪	4 h	精讀 BindCraft wiki 的 de novo binder design 頁（本 SOP §2 的來源）。 **動手**：開 ChimeraX 或 PyMOL，對一個練習靶點（規程未出前可用 EGF–EGFR `1IVO` 或 RBX-1 `P62877`）做出 3 個修剪版本，各寫一條熱點字串，兩種格式都寫一遍。 **理由**：這是你日常工作的全部操作面。
D3	表達系統的物理界限	3 h	讀 Adaptyv 的無細胞表達技術頁與 improve-protein-expression 指南。 **動手**：寫 §4.2 的組成檢查腳本。 **理由**：你要能判斷一條設計在那管液體裡會發生什麼——完全重構的大腸桿菌無細胞系統、T7 聚合酶跑線性雙鏈 DNA、無醣基化、無分子伴侶（chaperone）豐富的細胞質、無包涵體（inclusion body）救援，設計必須一次摺對。
D4	在真實資料上校準	4 h	下載 `adaptyvbio/egfr_competition_2`（378 條含實測表達與 KD）。自己重算 E%／K% 的 ROC AUC，與 ipTM 並排畫出來。 **理由**：這天最有價值。你會親眼看到 0.77 對 0.58 的差距，而不是從二手資料聽來。這份圖之後是你說服隊友的證據，也是理由書裡可以引用的材料。
D5	感測圖與理由書	3 h	讀 §7 的判讀清單；用練習靶點寫出第一版靶點檔案（含 200–400 字表位理由）。 **理由**：讓整條流程在真資料進來前先空跑一遍。
D6+	VHH 架構（**研究缺口**）	待定	長江杯的題目是奈米抗體（nanobody / VHH）或微型結合蛋白（minibinder）。若走 VHH，需自補：FR1–FR4 框架區、CDR 長度分布、使 VHH 無輕鏈仍可溶的疏水核心取代、CDR1–CDR3 雙硫鍵、人源化（humanisation）與可開發性（developability）。**本次研究未能取得這部分資料**，起點建議為 RFantibody 的 bioRxiv 全文。

B.1 ・ 工具安裝清單（半天）

- ChimeraX 或 PyMOL（結構檢視與修剪）
- NetSolP、SoluProt、Aggrescan3D（溶解度與聚集）
- Python 環境 + 你的組成檢查腳本
- Foldseek（界面／結構多樣性分群，供 §5 配額用）

B.2 ・ 參考資源

資源	網址
BindCraft wiki（熱點、修剪、過濾、硬體）	`github.com/martinpacesa/BindCraft/wiki/De-novo-binder-design-with-BindCraft`
Adaptyv 社群論文（本 SOP 多數數字的來源）	`biorxiv.org/content/10.1101/2025.04.17.648362v2.full`
Round 2 資料集（378 條實測）	`github.com/adaptyvbio/egfr_competition_2/`
Adaptyv 無細胞表達技術頁	`docs.adaptyvbio.com/wiki/technologies/cell-free-protein-expression`
Adaptyv 改善表達指南	`docs.adaptyvbio.com/guides/improve-protein-expression`
EMBL-EBI AlphaFold 課程（置信度分數模組）	`ebi.ac.uk/training/online/courses/alphafold`
APDI 結合物設計工作坊（修剪與熱點的實務提示）	`australian-protein-design-initiative.github.io/binder-design-workshop/`
統合分析（15 靶點 3,766 設計）	`biorxiv.org/content/10.1101/2025.08.14.670059v1.full`
RFantibody 預印本（VHH 自補用）	`biorxiv.org/content/10.1101/2024.03.14.585103`

附錄 C ・ 不要當成事實使用的項目

項目	狀態	關閉缺口的動作
`pae_interaction < 10` 這個社群廣傳的閾值	**無法由一手來源證實**。`dl_binder_design` 的 README 只點名該指標最具預測性、未給數字	**不要寫進團隊 SOP 或登錄表**
長江杯的靶點、提交上限、長度與格式限制、篩選指標、獎金分配	完全未公開（非遺漏，是公開網路上不存在）	官方信箱 + 香港中文大學共同發起方管道
長江杯 10 月 31 日報名截止	單一來源	立即去信確認
Adaptyv 附加標籤的身分與端點（His／Avi、N 端／C 端）	文件頁無法取得	去信詢問；影響結合界面能否貼近端點
疏水斑塊大小、表面電荷、淨電荷的數值門檻	無任何公開數值；規則僅到定性層次	以 Round 2 資料集自行校準分布
半胱胺酸含量、GC 含量、同聚物串、稀有密碼子造成的失敗率	在任何 Adaptyv 資料集中**皆未被量化**，僅被列為機制	視為定性風險，不要設硬閾值
EGFR 靶點構築體的醣基化狀態與邊界	未見於任何可取得的來源	不要臆斷任一方向
VHH 架構細節（FR 區、CDR 長度、人源化）	本次研究未取得	讀 RFantibody 預印本全文
生物層干涉術（BLI）的具體儀器平台	來源僅寫「BLI」；**不要斷言是 Octet**。亦無來源指出使用表面電漿共振（SPR）	—
Round 1 的結合物計數	主辦方貼文內部不一致（5 強 + 2 弱 ／ 7 條中 3 條為真）	引用時註明
Round 2 名次 2–3、BindCraft 最佳 KD（82 vs 91.5 nM）	不同來源說法衝突	引用時取官方結果貼文
§5 多樣性配額的百分比	**本文件的構造**，無來源發表過配額比例	以第一輪實測結果校正
本 SOP 的「不可妥協知識清單」	無任何主辦方發布過參賽者課綱；為依平台機制推理而成	視為合理建議，非官方要求

> **來源品質說明**。本 SOP 的主要數字來自兩份 **bioRxiv 預印本**（10.1101/2025.04.17.648362 與 10.1101/2025.08.14.670059，**均未經同儕審查**）、Adaptyv 官方 Round 2 資料庫、以及 Adaptyv 自家文件與部落格（**主辦方自我報告**，且含至少一處主辦方自己承認的內部不一致）。BindCraft 的 Nature 論文與其 PMC 鏡像在研究期間均無法取得，故 BindCraft 的細節為間接取得。